

CS336 Assignment 3: Scaling

IsoFLOPs、Scaling Laws 与离线 Proxy 外推

ShaneLiu04

2026 年 10 月 3 日

摘要

本文实现 IsoFLOPs compute-optimal scaling、联合 loss law、bootstrap uncertainty 与 held-out diagnostics，并在 RTX 6000D 上执行 TinyStories proxy scaling matrix。官方 72 条合成记录给出 $N_{\text{opt}} \propto C^{0.469}$ 、 $D_{\text{opt}} \propto C^{0.531}$ ； 10^{23} FLOPs 预测约 70.1B 参数与 237.9B tokens， 10^{24} FLOPs 预测约 206.1B 参数与 808.6B tokens。本文是自学记录；未访问 Stanford B200 Training API，也未提交官方 leaderboard configuration。

目录

1	范围、诚信与可复现性	2
2	Compute-optimal 问题	2
3	Problem 1: 官方 IsoFLOP Scaling	2
3.1	参数与数据幂律	2
3.2	拟合质量与外推风险	3
4	RTX 6000D Proxy Scaling	3
5	Uncertainty 与模型诊断	8
6	48 B200-hour 方法学（非官方提交）	8
7	结论	11
A	复现命令	11

1 范围、诚信与可复现性

[资源受限] Assignment 3 的计分训练必须通过 Stanford hosted B200 API，并受 12 B200-hour 拟合预算约束。本项目没有 A3 API key，因此 Part 2 采用公开数据与 RTX 6000D TinyStories proxy 完整演示方法学。Proxy 结论不能替代 DCLM、B200 或 /final_submission。

官方数据固定为 staff GitHub raw URL，并记录 SHA-256。报告资产位于 `report/results/`: raw、figures、tables、summary、experiment log 与 manifest。每个 proxy run 保留 config/environment/metrics/summary；OOM 与失败同样归档。

2 Compute-optimal 问题

设 non-embedding parameters 为 N 、训练 tokens 为 D 。Transformer 训练计算量近似

$$C \approx 6ND.$$

固定 C 时，大模型意味着更少 tokens，小模型意味着更多 tokens。两端都会损失：过大的模型 under-trained，过小的模型 capacity-limited，故 IsoFLOP profile 呈 U 形。




图 1: 官方 9 个 compute tiers 的 IsoFLOP profiles; 每 tier 直接取离散最低点，不用二次曲线制造网格外 minimum。

3 Problem 1: 官方 IsoFLOP Scaling

3.1 参数与数据幂律

对每个 tier 的离散 minimum 拟合

$$N_{\text{opt}}(C) = A_N C^a, \quad D_{\text{opt}}(C) = A_D C^b.$$




图 2: Compute-optimal model size 及外推点; error bar 为 tier bootstrap 95% interval。

[实测] 拟合得到 $a = 0.4687$ 、 $b = 0.5313$ ，两者和为 1，符合 $C = 6ND$ 的代数约束。数值答案为：

Compute	N_{opt}	D_{opt}
10^{23} FLOPs	70.05B	237.91B tokens
10^{24} FLOPs	206.12B	808.60B tokens

3.2 拟合质量与外推风险

[实测] 联合模型

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta}$$

在 72 点上的 grid-profile fit 得到 $\alpha = 0.339$ 、 $\beta = 0.363$ 、RMSE 0.00147。小 RMSE 不代表 10^{24} 外推确定：目标 compute 比最大观测值高约 333 倍，model grid 的离散 winner、measurement noise 与 functional-form choice 都会被放大。

4 RTX 6000D Proxy Scaling

Proxy 使用 TinyStories 10K tokenizer、context 256、固定 optimizer/data order，并扫描约 3M/11M/25M/57M non-embedding parameters 与三个 compute tiers。其目标是验证 analysis pipeline 和 finite-grid bias，而非预测 DCLM leaderboard。




图 3: Compute-optimal dataset size 及外推点。




图 4: 离散 optima 在 log space 中相对参数幂律的残差。




图 5: Compute tier 增长时的最低 loss 与 compute-optimal tokens/parameter ratio。




图 6: 官方数据各 compute tier 的 run 覆盖; 均匀的 profile 密度降低 winner selection bias。





图 7: TinyStories proxy IsoFLOP profiles。

图 8: Proxy 的 N_{opt} 、 D_{opt} 与幂律。




图 9: 不同规模和 token budget 的 validation curves。




图 10: 每个 proxy run 的参数数量、tokens、理论 FLOPs 与 wall-clock allocation。




图 11: 各 proxy tier 的离散 winner; 最低 tier 落在 0.8M 扫描边界。

[实测]22 个 proxy runs 给出 $N_{\text{opt}} \propto C^{0.676}$ 、 $D_{\text{opt}} \propto C^{0.324}$, 明显不同于官方 0.469/0.531。四个 tier 的 winner 从 0.8M 移至 3.1M, 最高 tier 再移至 10.6M; 最低 tier 仍落在扫描边界。Exponent 对离散 winner 与 domain 极敏感, 因此 proxy 适合展示 finite-grid bias, 不适合外推 B200/DCLM。

解释原则。 如果某 tier 的 minimum 落在扫描边界, 幂律点只提供 bound, 而非 interior optimum; 如果大模型因 compile overhead 或低利用率使 wall-clock/FLOPs 比例变化, 则 wall-clock optimal 与 FLOP-optimal 不同。报告同时展示离散 winner 与拟合线, 避免隐藏 winner's curse。

5 Uncertainty 与模型诊断

Bootstrap 必须按 compute tier 重采样, 而不是把同 tier 的高度相关 runs 当独立样本。Held-out tier 误差比 in-sample RMSE 更接近真实外推风险; 随着目标远离观测范围, confidence interval 应变宽, 而不是因 log-linear fit 看似平滑而变窄。

6 48 B200-hour 方法学 (非官方提交)

若具备 API access, 推荐流程为: (1) 少量 calibration runs 估计有效 FLOP/s; (2) 4-5 个 IsoFLOP tiers, 每 tier 3-5 个模型规模; (3) 在最优附近做 LR/batch/warmup 消融; (4) 保留确认预算; (5) 用 completed runs 的 runtime 建立 wall-clock correction。参数量近似 $12n_{\text{layer}}d_{\text{model}}^2$, tokens 必须按 $512 \times \text{batch}$ 对齐。

[资源受限] 本报告不提供 fabricated 48-hour loss 或 training config。官方 final prediction 需要真实 API response 中的 used_runtime_seconds 与 validation loss; RTX 6000D proxy 只能说明建模步骤和风险控制。




图 12: 重采样得到的 scaling exponents 分布与 95% interval。




图 13: 联合 law 在 (N, D) 空间的 loss surface 与观测点。




图 14: Leave-one-tier-out prediction 与 observed minima。




图 15: 离散 minimum、profile interpolation 与联合 law 对大尺度预测的敏感性。

7 结论

官方合成数据支持近似 balanced scaling, 但 a, b 并非普适常数。高质量 scaling recipe 应同时满足: (1) 每 tier 有 interior minimum; (2) compute 与 runtime 可追溯; (3) held-out error 可接受; (4) 外推 interval 随距离扩大; (5) 超参选择与 scaling fit 分层进行。增加低价值 runs 不如扩大 tier 覆盖、补边界模型或重复关键 minimum。

A 复现命令

```
uv sync
uv run python scripts/analyze_scaling.py
uv run python scripts/build_report_assets.py
cd report && make
```

致谢与使用声明

本项目由 [ShaneLiu04](#) 完成, 用于个人自学与公开学习记录, 不是 Stanford 课程提交。官方材料版权归原作者所有。