

CS336 Assignment 4: Data

从 Common Crawl 到可训练语料

ShaneLiu04

2026 年 10 月 3 日

摘要

本文实现 HTML extraction、language identification、PII masking、NSFW/toxicity、Gopher quality rules、quality classification、exact line 与 MinHash deduplication, 并建立 GPT-2 tokenization 与可复现过滤流水线。全部 21 项公开测试通过; 400 篇受控文档、1000 条真实 WET records、12 组 filter ablations 与 23 组图用于解释每个 stage 的行为。本文为未使用 Modal/SUNET_ID, 也不声称 2500-WET 或 8×B200 leaderboard 成绩。

目录

1 范围、数据契约与实验方法	2
2 Common Crawl 与文本抽取	2
3 Language identification 与 PII	2
4 有害内容与质量过滤	3
5 过滤漏斗与阈值消融	5
6 真实 Common Crawl WET 分布	5
7 Deduplication	5
8 Tokenization 与训练	10
9 验证与局限	10
10 结论	10
A 复现命令	10

1 范围、数据契约与实验方法

官方目标是从 Common Crawl 构建 GPT-2 training bin, 并在 Paloma C4 100 domains 上比较 validation loss。离线模式只使用公开 fixtures、可下载 classifiers 与 controlled proxy; 不把 Paloma validation 文本并入训练数据。每个过滤阶段记录 documents/chars/tokens、keep rate、runtime 与 rejection reason, 图由 raw JSON 自动生成。

2 Common Crawl 与文本抽取

WARC 保留 HTTP payload 和 metadata, 适合重新抽取、链接/域分析与 HTML-aware filtering; WET 只保留预抽取文本, 体积更小、处理更快, 但丢失 DOM 结构并继承 Common Crawl extractor 错误。高质量页面常包含完整叙事、技术文档或百科条目; 导航页、cookie banner、SEO 堆词、404 和模板页不适合作为 language-model training data。

实现先用 encoding detection 解码 bytes, 再由 Resiliparse 提取 visible text。Fixture 与 golden text 逐字一致, 说明段落与实体处理满足测试契约。

3 Language identification 与 PII

语言识别优先使用 fastText lid.176, 返回 label 与非负 confidence; 模型不可用时仅为测试提供 Unicode-script fallback。生产阈值建议 $P(\text{en}) \geq 0.7$ 。阈值过低引入多语噪声, 过高会伤害 code-switching、专有名词和短文档召回。

PII 使用边界敏感 regex 掩码 email、美国电话号码和合法 IPv4, 并返回 replacement count。掩码而非删除可保留句法位置, 但 regex 无法覆盖所有国际号码/IPv6, 且可能把示例地址误当真实 PII。




图 1: 受控语料中的 PII replacement counts; 该图用于验证计数管线。

4 有害内容与质量过滤

NSFW/toxic 优先使用 Dolma Jigsaw fastText; 离线无模型时采用可解释 lexical fallback。Safety score 不应被解释为真实概率，且阈值会改变 domain distribution。




图 2: 各受控文档组的 NSFW score 分布。




图 3: 各受控文档组的 toxic score 分布。

Gopher rules 检查 50–100k non-symbol words、平均词长 3–10、ellipsis line ratio 与 alphabetic-word ratio。规则便宜且可解释，应放在 expensive classifier 前。

Quality classifier 的生产版本应由 Wiki 外链正样本与随机 CC 负样本训练，并保留 holdout；本离线实现将相同 interpretable features 映射为 cc/wiki score，以保证测试和流水线可复现。




图 4: 不同 corruption groups 的 Gopher pass rate。




图 5: 文档长度分布解释 short-document rejection。




图 6: Quality score 的 group separation。

5 过滤漏斗与阈值消融

阈值调优不能只最大化 keep rate: 高召回保留更多低质量模板, 高精度可能造成 domain collapse。高质量方案应联合 Paloma loss、token yield 与 domain coverage 选择, 而不是单看 classifier accuracy。

6 真实 Common Crawl WET 分布

真实 WET 分析与受控 corpus 的角色不同: 前者测 distribution 与 filter yield, 后者隔离规则边界。样例文件不能代表 2500 WET 全量, 因此 domain proportion 和 toxicity rate 只作 exploratory evidence; 但它能揭示 fixture 无法覆盖的 score overlap、长尾长度与 PII incidence。[实测] 在 1000 条真实 WET records 中, lid 模型判为 English 325 条、Chinese 239 条, 其余分布于 30 多种语言; 733 条通过 Gopher, 88 条被 quality heuristic 判为 Wiki-like, NSFW/toxic 分别为 12/24 条。该样例来自 paths 文件第一 shard, 并非随机全库样本, 因此这些比例不能外推 Common Crawl 全量, 但足以说明 language filtering 与 quality filtering 分别解决不同噪声来源。

7 Deduplication

Exact line deduplication 使用两趟全局计数: 第一趟统计 normalized line hash, 第二趟只写全局频次为 1 的行; 每个输入文件仍产生输出, 即使为空。该策略去除 boilerplate, 但也可能删除合法高频短句。

MinHash 将 NFD、小写、标点/空白与重音规范化后的 word n-grams 映射成 signatures; LSH 只生成 candidate pairs, 最终用真实 Jaccard threshold 确认并通过 deterministic union-find 每簇保留一篇。测试覆盖 exact duplicates 与 MIT license fuzzy duplicates。生产环境需按 band bucket 分片落盘, 避免 2500 WET signatures 全驻内存。




图 7: Wiki-like/CC-like heuristic decision matrix。




图 8: 代表性 Gopher+quality+safety pipeline 的 document funnel。




图 9: 12 个消融配置的 rejection reason decomposition。




图 10: Quality threshold 与 corpus yield 的 Pareto curve。




图 11: Gopher、safety 与 threshold 的 keep-rate 对照。




图 12: Character yield: document count 相同不代表训练 tokens 相同。




图 13: Document yield。




图 14: 受控 corpus 上各 filter combination 的 wall-clock。




图 15: 官方 example WET records 的语言预测分布。

8 Tokenization 与训练

每篇保留文档使用 GPT-2 tokenizer, 文档末尾追加 EOT, token IDs 以 `np.uint16.tofile` 写入 flat binary。必须按 document 而非按 arbitrary line 追加 EOT, 否则改变 sequence boundary distribution。

[资源受限] 官方终训为 $8 \times B200$ 、16384 steps、约 8.6B sampled tokens; 单张 RTX 6000D 即使运行同样 steps 也只有约 1/8 sampled tokens。离线受控语料不足以支持有意义的 430M full training, 因此本报告不运行“高占用率但重复采样严重”的伪 leaderboard 实验。GPU 应保留给至少数十亿 token 的数据版本比较; 当前最有价值证据是过滤正确性与数据统计。

9 验证与局限

[实测] 全量 pytest 为 21 passed、0 failed。规则与 fixture correctness 不等于 web-scale precision: fastText 模型下载、Wiki-vs-CC classifier、2500-WET global MinHash 和 Paloma downstream training 仍需 Modal 权限。报告明确区分已实测、proxy 与资源受限项目。

10 结论

高质量 data pipeline 的核心不是叠加最多 filters, 而是可追溯的 stage-wise trade-off: cheap rules 先降噪, semantic classifier 控制 quality, PII/safety 降低风险, global dedup 降低重复, 最终用 downstream validation loss 决策阈值。任何 filter 都可能引入 domain bias, 因此必须同时保存被丢弃样本和 score distributions。

A 复现命令




图 16: 语言 confidence 分布用于解释 0.7 threshold 的召回风险。




图 17: 真实 WET quality score 分布。




图 18: NSFW 与 toxic scores 的关系；两者不可互相替代。




图 19: 文档长度与 quality score; 长文档不自动等于高质量。




图 20: 样例 WET top domains, 展示 Web source concentration。




图 21: 真实 WET 的 language→Gopher→quality 漏斗。




图 22: 真实 WET 中检测到的 email/phone/IPv4 数量。




图 23: 全部 21 项 extraction/language/PII/quality/toxicity/dedup tests 通过。

```
python -m pytest -q tests
PYTHONPATH=. python scripts/run_offline_experiments.py
python scripts/build_report_assets.py
cd report && make
```

致谢

本项目由 [ShaneLiu04](#) 完成；课程材料版权归原作者所有。