

CS336 Assignment 5: Alignment

GRPO、Off-policy 与 Preference Optimization

ShaneLiu04

2026 年 10 月 3 日

摘要

本文实现 GRPO/Dr.GRPO/MaxRL/RFT、off-policy token/sequence importance weighting、SFT packing、metrics parsing 与 DPO loss。主测试和 supplement 测试共 26 项全部通过。由于没有 Modal/SUNET_ID，本报告使用 RTX 6000D 上 7 种 objective、4 seeds、160 steps 的向量化 bandit proxy (4480 条 raw metrics) 分析 normalization、length bias 与 clipping。这是自学记录，不冒充 OLMo-2/GSM8K 或 B200 正式结果。

目录

1 目标、范围与验证	2
2 Tokenization、log probability 与 reward	2
3 GRPO Advantage 与 Baseline	2
4 Policy Gradient 与 Length Bias	3
5 On-policy Objective Comparison	3
6 Off-policy GRPO 与 GSPO	3
7 Sampling 与 pass@k	9
8 SFT Packing、Metrics 与 DPO	9
9 资源边界与下一步	9
10 结论	11
A 复现	11

1 目标、范围与验证

Alignment 的核心是把 sequence-level reward 转成稳定的 token-level gradient，同时控制 sampling distribution 与 training distribution 的偏移。实现由公开 snapshots 验证；proxy 仅隔离 objective mechanics，不代表 language reasoning。




图 1: GRPO 与 supplement 接口的测试覆盖。

2 Tokenization、log probability 与 reward

Prompt 与 response 先分别 tokenize，再拼接并 shift 成 input/labels；response mask 与 labels 对齐，padding/prompt token 不参与 policy loss。对 logits 使用 log-softmax 后 gather label 位置，entropy 为

$$H(p_t) = - \sum_v p(v \mid x_{<t}) \log p(v \mid x_{<t}).$$

Rollout grader 返回 format/answer/total rewards。Format 正确但答案错误是重要 error class，因为它说明 prompt compliance 与 reasoning accuracy 必须分开记录。

3 GRPO Advantage 与 Baseline

组内 reward r_i ，GRPO advantage 为

$$A_i = \frac{r_i - \bar{r}}{s_r + \epsilon}.$$

Baseline 不改变期望 gradient，但可降低方差；sample std normalization 又会按 group difficulty 加权。Dr.GRPO 不除 std，MaxRL 除 mean reward，RFT 不减 baseline。




图 2: 不同 group success probability 下 advantage scale。

GRPO 在极易/极难 group 中 std 很小, 会放大少数差异; Dr.GRPO 更稳定但失去 scale normalization; MaxRL 强调低成功率 group。没有一种 normalization 对所有 difficulty distribution 都最优。

4 Policy Gradient 与 Length Bias

On-policy per-token objective 为 $-A \log \pi_\theta(y_t|x, y_{<t})$ 。Sequence normalization 先除每条 response length, 再对 batch 平均; constant normalization 以固定 BGL 除总 loss。前者让短 response 每 token 权重更大, 后者保留 token-count 权重。

5 On-policy Objective Comparison

[实测]Proxy 中所有 objectives 都能提高正确动作概率, 但速度与 entropy collapse 不同。RFT 只强化 positive samples, 早期 signal 稀疏; GRPO/Dr.GRPO 使用 negative relative advantages, sample efficiency 更高。结果只证明 objective implementation behavior, 不能推断 GSM8K accuracy。

6 Off-policy GRPO 与 GSPO

旧策略 $\pi_{\theta_{old}}$ 产生 rollout 时, importance ratio

$$\rho_t = \exp(\log \pi_\theta(y_t) - \log \pi_{\theta_{old}}(y_t)).$$

Noclip 无偏但高方差; GRPO/PPO 在 token level clip ρ_t ; GSPO 对 response-mask 内平均 log-ratio 后做 sequence-level clip。




图 3: 不同 objectives 下 proxy response length。




图 4: 四 seeds 的 gradient norm trajectory。





图 5: Surrogate loss curves。

图 6: 7 种 objectives 的 answer reward, 曲线为 seed mean $\pm$ std。




图 7: Format reward 与 answer reward 的分离。




图 8: Policy entropy: reward 提升通常伴随 exploration 收缩。




图 9: 受控 correct-action probability。




图 10: Final proxy reward 及 seed uncertainty。




图 11: Final entropy 对比。




图 12: Final gradient norm 对比。




图 13: Token/sequence clipping fraction。

Cliprange 过小会让多数 samples 失去 gradient，过大则无法约束 stale rollout。Off-policy efficiency 必须同时报告 wall-clock、clip fraction、effective sample size 与 reward，而不能只比较 optimizer steps。

7 Sampling 与 pass@k

在独立采样近似下， $\text{pass}@k = 1 - (1 - p)^k$ 。Group rollout 提高发现正确答案的概率，但同一 prompt 的 samples 高度相关，真实 pass@k 通常低于独立估计。

8 SFT Packing、Metrics 与 DPO

Packed SFT 将多个 instruction examples 串接后切成固定长度 block，input 与 next-token labels shift 对齐；shuffle 只改变 document order，不丢 tokens。MMLU parser 只接受 A–D，GSM8K supplement parser 取最后 numeric answer，二者不能与 R1-zero XML grader 混用。

DPO 单样本 loss 为

$$-\log \sigma(\beta[(\log \pi_{\theta}(y_w|x) - \log \pi_{\theta}(y_l|x)) - (\log \pi_{\text{ref}}(y_w|x) - \log \pi_{\text{ref}}(y_l|x))])$$

Reference model 必须 no-grad；chosen/rejected 只在 response tokens 上累计 log probability。

9 资源边界与下一步

[资源受限] 正式作业要求 OLMo-2-1B、vLLM rollout、2×B200 Modal 与四 seeds；supplement 还需要 Llama-3.1-8B、HH/UltraChat 和 70B judge。单张 RTX 6000D 可承载 1B policy，但不能按 handout 同时提供训练与独立 vLLM GPU，也不能 bf16 运行 70B judge。因此本报告不伪造正式 accuracy/win-rate。




图 14: 由 final success probability 推导的 proxy pass@1/2/4/8。




图 15: GSM8K question/rationale word-length distribution。

下一步优先级: (1) 获得 Modal 权限后跑 50-step smoke; (2) standard GRPO 四 seeds; (3) 根据 seed variance 决定 LR/prompt sweep; (4) 再比较 Dr.GRPO/RFT/MaxRL; (5) off-policy 记录 ratio 与 clip fraction; (6) supplement 单独报告 alignment tax。

10 结论

高质量 alignment experiment 需要同时追踪 reward components、entropy、grad norm、response length、pass@k、clip fraction 与 seed variance。Reward 上升若伴随 format shortcut、entropy collapse 或 response-length drift, 不能简单解释为 reasoning 改善。

A 复现

```
python -m pytest -q tests/test_grpo.py tests/test_data.py tests/test_metrics.  
py tests/test_dpo.py  
python scripts/run_proxy_alignment.py  
python scripts/build_report_assets.py  
cd report && make
```

致谢

作者: [ShaneLiu04](#)。